

보 고 서

레이더 신호처리 및 인공지능

선택 사례 : P2 Micro-Doppler HAR

**과제 제목 : Target-Range Micro-Doppler Spectrogram 기반 사람
활동 인식에서 Aspect Angle 변화에 따른 ResNet-18
분류 성능 분석**

202560174

장 래 규

Target-Range Micro-Doppler Spectrogram 기반 사람 활동 인식에서 Aspect Angle 변화에 따른 ResNet-18 분류 성능 분석

Analysis of ResNet-18 Classification Performance under Aspect-Angle Variation for Human Activity Recognition Using Target-Range Micro-Doppler Spectrograms

장래규

충남대학교

ABSTRACT

This paper analyzes the classification performance of a ResNet-18 model for human activity recognition using target-range micro-Doppler spectrograms. Six activity classes, namely walk, run, sit_down, fall, wave, and idle, were considered. A baseline model was trained with simulated spectrograms generated under an aspect-angle range of 0-60 deg, a target range of 6-18 m, and an SNR range of 5-25 dB. The model achieved 100.0% accuracy on the in-distribution test set. To evaluate generalization, a held-out aspect/range test set was generated using an aspect-angle range of 60-80 deg and a target range of 18-26 m. The accuracy decreased to 89.0%, with the largest degradation observed for the walk class. The confusion matrix indicates that walk samples were mainly confused with wave and sit_down classes. These results show that high in-distribution accuracy does not necessarily guarantee robustness under observation-geometry changes. The experiment confirms the importance of stress testing when applying deep learning models to radar-based activity recognition.

초 록

본 논문은 target-range micro-Doppler spectrogram 을 이용한 사람 활동 인식 문제에서 ResNet-18 기반 분류기의 성능을 분석한다. 활동 클래스는 walk, run, sit_down, fall, wave, idle 의 6 개로 구성하였다. 기본 실험에서는 aspect angle 0-60 deg, target range 6-18 m, SNR 5-25 dB 조건에서 생성된 시뮬레이션 데이터를 사용하여 모델을 학습하였다. 동일 분포의 test set 에서는 100.0%의 정확도를 얻었다. 이후 모델의 일반화 성능을 검토하기 위해 aspect angle 60-80 deg 및 target range 18-26 m 조건의 held-out test set 을 생성하여 평가하였다. 해당 조건에서는 정확도가 89.0%로 감소하였고, 특히 walk 클래스의 성능 저하가 가장 크게 나타났다. Confusion matrix 분석 결과 walk 샘플은 주로 wave 및 sit_down 으로 오분류되었다. 이는 높은 동일 분포 정확도만으로는 관측 기하 변화에 대한 강건성을 보장하기 어렵다는 점을 보여준다. 따라서 레이더 기반 활동 인식 모델의 성능 평가에는 baseline 결과와 함께 aspect, range, SNR 변화에 대한 stress test 가 필요하다.

Key Words : Micro-Doppler(마이크로 도플러), Human Activity Recognition(사람 활동 인식), ResNet-18, Aspect Angle(관측 각도), Radar AI(레이더 인공지능)

I. 서 론

레이더 기반 사람 활동 인식은 카메라와 달리 조명 조건의 영향을 적게 받고 사생활 침해 우려가 비교적 낮아 감시, 보안, 헬스케어, 차량 탑승자 모니터링 등 다양한 분야에서 활용 가능성이 높다. 특히 인체는 몸통, 팔, 다리, 머리 등 여러 산란체의 결합으로 구성되며, 보행이나 달리기와 같은 활동에서는 각 산란체가 서로 다른 속도 성분을 갖는다. 이때 레이더 수신 신호에는 물체 전체의 병진 운동뿐 아니라 신체 일부의 미세 운동에 의한 주파수 변조 성분이 포함된다. 이러한 현상을 micro-Doppler 효과라 하며, 시간-주파수 영역에서 활동별 특징적인 패턴으로 나타난다.

Micro-Doppler 신호는 일반적으로 단일 시점의 스펙트럼보다 시간 변화 정보를 포함하는 spectrogram 형태로 분석된다. 활동 종류에 따라 Doppler spread, 주기성, 에너지 집중 영역, 정지 구간 등의 특징이 다르기 때문이다. 예를 들어 walk 와 run 은 팔과 다리의 반복 운동으로 인해 주기적인 Doppler ridge 가 나타나며, fall 은 짧은 시간 동안 급격한 변화가 발생한다. idle 은 전체 Doppler 확산이 작고, wave 는 몸통은 정지에 가깝지만 팔 움직임에 의한 국소적인 Doppler 성분이 나타난다. 이러한 특성은 합성곱 신경망(CNN)이 이미지 분류 문제처럼 학습하기에 적합한 형태를 제공한다.

하지만 레이더 기반 활동 인식의 성능은 데이터 생성 조건 또는 관측 조건에 크게 의존한다. 동일한

활동이라도 레이더가 관측하는 방향이 달라지면 radial velocity 성분이 달라지고, 결과적으로 spectrogram의 폭과 에너지 분포가 변화한다. 또한 target range가 증가하면 수신 신호 세기와 range profile 특성이 달라질 수 있다. 따라서 동일 분포 데이터에서 높은 정확도를 얻는 것만으로는 실제 운용 환경에서의 성능을 충분히 설명하기 어렵다.

본 연구에서는 ResNet-18 HAR 프로젝트를 대상으로 target-range micro-Doppler spectrogram 기반 6-class 활동 분류 실험을 수행하였다. 먼저 baseline 조건에서 모델을 학습하고 동일 분포 test set에 대한 정확도를 확인하였다. 이후 aspect angle과 target range를 학습 범위 밖으로 이동시킨 held-out test set을 생성하여 동일 모델의 일반화 성능을 평가하였다. 이를 통해 모델이 기본 분포에서는 충분한 분류 성능을 보이는지, 그리고 관측 기하 변화가 발생할 때 어떤 클래스가 취약해지는지를 분석하였다.

II. 본 론

2.1 Micro-Doppler 기반 활동 인식 개념

Micro-Doppler 효과는 산란체의 미세 운동이 레이더 수신 신호의 위상과 주파수에 추가적인 변조를 유발하는 현상이다. 단일 강체 표적의 Doppler 주파수는 주로 표적 중심의 radial velocity에 의해 결정되지만, 사람과 같은 비강체 표적은 팔과 다리의 주기적 운동이 추가로 반영된다. 이러한 미세 운동 성분은 시간에 따라 변하므로 시간-주파수 표현을 사용하면 활동별 signature를 시각적으로 구분할 수 있다.

본 실험에서 사용한 target-range 접근은 전체 range-Doppler map을 직접 사용하기보다 표적이 존재하는 range bin 주변의 slow-time 신호를 추출한 뒤 STFT를 적용하는 방식이다. 이는 불필요한 배경 range 성분을 줄이고 활동 분류에 직접적으로 관련된 표적 영역의 Doppler 변화를 강조할 수 있다. 결과적으로 입력 데이터는 1 채널 128×128 크기의 spectrogram 이미지가 되며, 이는 CNN 기반 분류기에 적합한 구조를 가진다. 관측 각도는 micro-Doppler signature를 변화시키는 핵심 요인이다. 레이더가 관측하는 속도 성분은 실제 운동 속도의 시선 방향 투영값이므로, aspect angle이 커지면 radial velocity가 감소한다. 이상적으로는 radial

component가 $\cos(\theta)$ 에 비례하여 축소되며, 이는 spectrogram 상에서 Doppler spread 감소로 나타난다. 따라서 학습 데이터가 주로 낮은 또는 중간 관측 각도를 포함한다면, 높은 관측 각도 조건의 데이터에서는 활동 간 차이가 줄어들어 오분류가 증가할 수 있다.



Fig. 1. Processing flow of target-range micro-Doppler HAR.

2.2 데이터 생성 조건 및 클래스 구성

데이터셋은 77 GHz FMCW 레이더 시뮬레이션 환경을 가정하여 생성되었다. 활동 클래스는 walk, run, sit_down, fall, wave, idle로 구성되며, 각 클래스는 서로 다른 인체 운동 패턴을 반영한다. Baseline 데이터는 aspect angle 0-60 deg, target range 6-18 m, SNR 5-25 dB 조건에서 생성하였다. 학습 데이터는 30,000 개, 검증 데이터는 3,000 개, 시험 데이터는 3,000 개로 구성하였다.

Held-out 데이터셋은 모델을 재학습하지 않고 일반화 성능을 평가하기 위한 별도 조건으로 생성하였다. 해당 데이터는 aspect angle 60-80 deg 및 target range 18-26 m 범위를 갖는다. SNR 범위는 baseline과 동일하게 5-25 dB로 유지하였다. 이 설정은 잡음 조건보다는 관측 기하와 거리 변화가 모델 성능에 미치는 영향을 확인하기 위한 것이다. Held-out 데이터는 test split 600 개를 사용하였으며, 기존 best_model.pt checkpoint를 그대로 평가하였다.

이러한 구성은 단순한 training accuracy 확인이 아니라 분포 변화(distribution shift)에 대한 stress test라는 점에서 의미가 있다. 동일 분포 성능이 높더라도 새로운 aspect와 range 조건에서 성능이 감소하면, 실제 시스템 적용 시 데이터 다양화 또는 domain generalization 전략이 필요함을 시사한다.

Item	Setting
Input	1 x 128 x 128 spectrogram
Classes	6 activities
Model	ResNet-18
Train / Val / Test	30000 / 3000 / 3000
Epoch	10
Device	CPU

Table 1. Experimental setup for ResNet-18 HAR.

2.3 ResNet-18 분류 모델

ResNet-18 은 residual connection 을 통해 깊은 신경망의 학습 안정성을 개선한 CNN 구조이다. 일반적인 CNN 은 층이 깊어질수록 gradient 소실 또는 성능 포화 문제가 발생할 수 있으나, residual block 은 입력을 출력에 더하는 shortcut 구조를 사용하여 이러한 문제를 완화한다. 본 실험에서는 micro-Doppler spectrogram 을 이미지로 간주하고 ResNet-18 을 6-class 분류 문제에 적용하였다.

입력 spectrogram 은 1 채널 형태이므로 일반적인 RGB 이미지와 달리 입력 채널 수가 1 이다. 모델의 최종 분류층은 6 개 활동 클래스에 대응하도록 구성하였다. 전체 학습 파라미터 수는 11,173,318 개이다. 학습은 CPU 환경에서 수행하였으며, 전체 10 epoch 동안 training loss 와 validation loss 를 기록하였다. CPU 환경에서는 1 epoch 당 약 8-19 분이 소요되었으며, 총 학습 시간은 약 99.9 분이였다.

분류 학습은 예측 클래스 확률과 정답 label 사이의 cross-entropy loss 를 최소화하는 방식으로 수행된다. 검증 손실은 매 epoch 마다 계산되며, 가장 낮은 validation loss 를 갖는 모델이 best checkpoint 로 저장된다. 본 실험에서 가장 낮은 validation loss 는 약 0.4210 으로 나타났으며, 이후 epoch 에서는 큰 변화 없이 안정화되는 경향을 보였다.

2.4 학습 결과 및 손실 변화

Fig. 3 은 10 epoch 동안의 training loss 와 validation loss 변화를 나타낸다. 1 epoch 에서 training loss 는 0.4604, validation loss 는 0.4484 였으며, 이후 2-4 epoch 구간에서 빠르게 감소하였다. 6 epoch 이후에는 training loss 와 validation loss 가 모두 약 0.421 부근에서 안정화되었다. 이는 모델이 기본 분포에서 필요한 특징을 비교적 빠르게 학습했음을 의미한다.

학습 곡선을 보면 training loss 와 validation loss 사이의 차이가 크지 않다. 이는 baseline 분포 안에서 심각한 과적합이 관찰되지 않았음을 의미한다. 다만 validation set 또한 동일한 생성 분포에서 만들어졌기 때문에, 이 결과만으로 실제 일반화 성능이 충분하다고 판단할 수는 없다. 따라서 본 연구에서는 별도의 held-out aspect/range 조건을 적용하여 추가 평가를 수행하였다.



Fig. 3. Training and validation loss for 10 epochs.

2.5 Baseline 평가 결과

Baseline test set 은 학습 및 검증 데이터와 동일한 aspect, range, SNR 범위에서 생성되었다. 평가 결과 전체 정확도는 100.0%로 나타났으며, 6 개 클래스 모두 100.0%의 class accuracy 를 보였다. Confusion matrix 에서도 모든 샘플이 대각 성분에만 위치하여 오분류가 발생하지 않았다. 이러한 결과는 ResNet-18 모델이 시뮬레이터가 생성한 baseline 분포의 활동별 spectrogram 패턴을 충분히 학습했음을 의미한다. 특히 동일 분포 조건에서는 walk, run, fall 과 같이 동적 패턴이 강한 클래스뿐 아니라 sit_down, wave, idle 과 같은 상대적으로 구분이 어려울 수 있는 클래스도 완전히 분류되었다. 그러나 baseline 정확도 100.0%는 데이터셋이 controlled simulation 환경에서 생성되었다는 점을 고려하여 해석해야 한다. 실제 레이더 환경에서는 센서 캘리브레이션, clutter, multi-path, 사람 체형 차이, 보행 방향, 속도 변화 등 다양한 요인이 존재한다. 따라서 baseline 결과는 모델 구현과 기본 학습 가능성을 확인하는 지표로 활용하고, 강건성 평가는 별도 stress test 결과와 함께 해석하는 것이 바람직하다.




Fig. 4. Overall accuracy comparison between baseline and held-out tests.

Experiment	Train	Test	Acc. (%)
Baseline	0-60 deg, 6-18 m	same distribution	100.0
Held-out	0-60 deg, 6-18 m	60-80 deg, 18-26 m	89.0

Table 2. Overall performance comparison.

2.6 Held-out aspect/range 평가 결과

Held-out 평가에서는 학습된 ResNet-18 checkpoint 를 고정하고, aspect angle 60-80 deg 및 target range 18-26 m 조건의 test set 600 개를 평가하였다. 이 조건은 baseline 학습 범위인 aspect angle 0-60 deg 및 target range 6-18 m 를 벗어난다. 평가 결과 전체 정확도는 89.0%로 나타났으며, baseline 대비 11.0%p 감소하였다.

클래스별 성능을 보면 fall 과 idle 은 각각 100.0% 정확도를 유지하였다. 반면 walk 는 70.0%로 가장 낮은 성능을 보였고, run 은 85.0%, sit_down 은 87.0%, wave 는 92.0%를 기록하였다. 이 결과는 모든 클래스가 관측 기하 변화에 동일하게 영향을 받는 것이 아니라, activity signature 의 형태와 radial velocity 의존도에 따라 취약성이 다르게 나타남을 의미한다.

특히 walk 와 run 은 팔과 다리의 반복 운동을 포함하므로 micro-Doppler spread 가 중요한 구분 단서가 된다. Aspect angle 이 증가하면 시선 방향 속도 성분이 감소하여 Doppler spread 가 축소되고, 그 결과 walk 의 고유한 주기적 패턴이 약해질 수 있다. 이에 비해 fall 은 짧은 시간 동안 급격한 자세 변화가 나타나므로 held-out 조건에서도 상대적으로 명확하게 구분된 것으로 보인다.




Fig. 5. Per-class accuracy comparison.

Class	Baseline	Held-out	Drop
walk	100.0	70.0	30.0
run	100.0	85.0	15.0
sit_down	100.0	87.0	13.0
fall	100.0	100.0	0.0
wave	100.0	92.0	8.0
idle	100.0	100.0	0.0

Table 3. Per-class accuracy under baseline and held-out conditions.

2.7 Confusion matrix 분석

Fig. 6 은 held-out aspect/range test set 에 대한 confusion matrix 를 나타낸다. 클래스 순서는 walk, run, sit_down, fall, wave, idle 이다. Walk 클래스는 총 100 개 중 70 개만 정확히 분류되었고, 21 개는 wave, 9 개는 sit_down 으로 분류되었다. Run 클래스는 85 개가 정확히 분류되었으며, 6 개는 walk, 8 개는 sit_down, 1 개는 wave 로 오분류되었다.

Sit_down 클래스는 87 개가 정확히 분류되었고 13 개가 idle 로 분류되었다. 이는 앉는 동작의 후반부 또는 움직임이 약한 구간이 idle 과 유사한 spectrogram 을 만들었을 가능성을 시사한다. Wave 클래스는 92 개가 정확히 분류되었고 8 개가 idle 로 분류되었다. 팔 움직임이 작게 관측되거나 aspect angle 로 인해 radial component 가 줄어들면 wave 의 Doppler signature 가 약해져 정지 상태와 유사해질 수 있다.

이러한 오분류 양상은 단순한 정확도 수치보다 모델의 약점을 구체적으로 보여준다. 전체 정확도는 89.0%로 비교적 높지만, walk 와 sit_down 의 일부 샘플은 관측 조건 변화에 민감하다. 따라서 실제 적용을 고려할 경우 walk, run, wave 처럼 동작 속도와 방향 의존성이 큰 클래스에 대해 다양한 aspect 조건을 포함한 학습 데이터 확장이 필요하다.




Fig. 6. Confusion matrix for held-out aspect/range test set.

2.8 관측각 변화에 따른 성능 저하 원인

레이더의 Doppler 측정은 표적 속도 벡터 중 레이더 시선 방향 성분에 의해 결정된다. 표적의 실제 운동 속도가 동일하더라도 레이더와 운동 방향 사이의 각도가 커지면 radial velocity 가 감소한다. 이때 Doppler 주파수는 파장에 반비례하고 radial velocity 에 비례하므로, 관측 각도가 커질수록 spectrogram 의 수직 방향 확산 폭이 줄어든다.

Baseline 데이터는 aspect angle 0-60 deg 조건을 포함하지만, held-out 데이터는 60-80 deg 로 더 큰 각도 범위를 가진다. 이 범위에서는 팔과 다리의 움직임이 레이더 방향으로 투영되는 성분이 작아지므로, walk 와 run 의 차이를 구분하는 고주파 Doppler ridge 가 약해질 수 있다. 또한 target range 가 멀어지면 신호 세기와 잡음 영향, target range bin 의 특성도 baseline 과 달라질 수 있다.

결과적으로 모델은 baseline 조건에서 학습한 feature 를 held-out 조건에 그대로 적용할 때 일부 클래스에서 confidence 가 낮아지거나 유사 클래스 방향으로 예측이 이동할 수 있다. 본 실험의 confusion matrix 에서 walk 가 wave 및 sit_down 으로 혼동된 점은 이러한 현상을 잘 보여준다. 즉, spectrogram 기반 CNN 은 이미지 패턴을 효과적으로 학습할 수 있지만, 그 패턴이 관측 기하에 의해 변형될 때는 성능 저하가 발생할 수 있다.

2.9 결과의 의미 및 한계

본 실험의 첫 번째 의미는 baseline 성능과 generalization 성능을 분리하여 해석했다는 점이다. 동일 분포 test set 에서 100.0% 정확도를 얻었다는

사실은 모델 구조와 학습 파이프라인이 정상적으로 동작함을 보여준다. 그러나 held-out 조건에서 89.0%로 감소한 결과는 실제 운용 환경에서 단일 조건 학습만으로는 충분하지 않을 수 있음을 보여준다.

두 번째 의미는 클래스별 취약성을 확인했다는 점이다. Fall 과 idle 은 held-out 조건에서도 강건했으나, walk 는 가장 큰 성능 저하를 보였다. 이는 레이더 HAR 모델의 성능을 전체 정확도 하나로만 평가하면 특정 클래스의 취약성이 가려질 수 있음을 의미한다. 실제 응용에서는 낙상 감지와 같이 특정 클래스의 recall 이 중요한 경우가 있으므로 class-wise metric 과 confusion matrix 가 필수적이다.

본 실험의 한계도 존재한다. 첫째, 데이터는 시뮬레이션 기반이므로 실제 측정 데이터의 clutter, multipath, calibration error, 인체 다양성 등을 모두 반영하지 못한다. 둘째, held-out 조건은 aspect angle 과 range 를 동시에 변화시켰기 때문에 두 요인의 영향을 완전히 분리하지는 못한다. 셋째, 10 epoch 학습 결과를 사용하였으므로, 더 긴 학습 또는 hyperparameter tuning 에 따른 성능 차이는 추가 검토가 필요하다.

2.10 재현 방법 및 산출 파일

실험은 Windows PowerShell 환경에서 Python 가상환경을 구성하여 수행하였다. CPU-only PyTorch를 설치한 뒤 P02 프로젝트 폴더에서 데이터 생성, 학습, held-out 평가를 순차적으로 실행하였다. Baseline 학습은 python train.py --generate --epochs 10 명령으로 수행하였고, 결과 파일은 artifacts 폴더에 저장되었다. Held-out 데이터셋은 generate_data.py 를 이용하여 n_train 0, n_val 600, n_test 600 조건으로 생성하였다. Aspect range 는 60-80 deg, target range 는 18-26 m 로 설정하였다. 이후 evaluate_checkpoint.py 를 이용해 artifacts/best_model.pt checkpoint 를 평가하였다. 최종적으로 eval_results.json, history.json, heldout_aspect_range_resnet18.json, best_model.pt 가 주요 산출 파일로 생성되었다. 보고서 재현을 위해서는 코드 저장소, 학습 이력, 평가 결과 JSON 파일, 그리고 checkpoint 파일이 필요하다. 특히 history.json 은 epoch 별 학습 및 검증 손실을 포함하고, heldout_aspect_range_resnet18.json 은

held-out 조건의 정확도, class-wise accuracy, confusion matrix 를 포함한다.

2.11 주요 수식 및 특징 변화 해석

레이더 기반 HAR 에서 spectrogram 특징은 물리적 Doppler 관계와 직접적으로 연결된다. 단일 산란체의 Doppler 주파수는 일반적으로 $f_D = 2 v_r / \lambda$ 로 표현할 수 있으며, 여기서 v_r 은 radial velocity, λ 는 레이더 파장이다. 인체의 팔과 다리처럼 여러 산란체가 동시에 움직이면 각 산란체의 radial velocity 가 서로 달라지고, 이 성분들이 시간에 따라 변하면서 micro-Doppler spectrogram 을 형성한다. STFT 는 시간에 따라 변화하는 Doppler 성분을 관찰하기 위한 기본 도구이다. 느린 시간 신호 $x[n]$ 에 대해 창 함수 $w[n]$ 을 적용하고 주파수 영역으로 변환하면 $S(m,k) = |\sum_n x[n]w[n-m]\exp(-j2\pi k n/N)|^2$ 형태의 시간-주파수 에너지 분포를 얻을 수 있다. 본 실험에서는 이 결과를 128×128 이미지로 정규화하여 CNN 입력으로 사용하였다. Aspect angle 변화는 위 수식에서 v_r 항을 변화시키는 요인이다. 실제 운동 속도가 일정하더라도 레이더 시선 방향 투영 성분이 감소하면 f_D 가 감소한다. 따라서 spectrogram 상의 ridge 가 중앙에 가까워지고, 서로 다른 활동 간의 Doppler 폭 차이가 작아진다. 이 때문에 동일 분포에서 잘 분리되던 클래스도 held-out 조건에서는 혼동될 수 있다. Cross-entropy loss 는 모델이 정답 클래스에 높은 확률을 부여하도록 학습시키는 목적 함수이다. 본 실험의 validation loss 가 약 0.421 부근에서 안정화되었다는 것은 baseline 분포에 대한 분류 경계가 빠르게 수렴했음을 의미한다. 그러나 loss 안정화는 동일 분포 검증 데이터에 대한 결과이므로, held-out 조건에서의 성능 보장을 직접 의미하지는 않는다.

2.12 개선 방향 및 추가 실험 제안

향후 개선 방향은 크게 데이터 측면, 모델 측면, 평가 측면으로 구분할 수 있다. 데이터 측면에서는 학습 단계에서 0-60 deg 뿐 아니라 60-80 deg 이상의 aspect angle 을 포함하도록 dataset diversity 를 높이는 것이 가장 직접적인 방법이다. 또한 range 조건을 더 넓게 분포시키고 SNR 을 낮은 영역까지 포함하면 실제 환경에 가까운 강건성을 확보할 수 있다.

모델 측면에서는 ResNet-18 외에 경량 CNN, attention 기반 구조, temporal modeling 구조를 비교할

수 있다. 현재 입력은 2D spectrogram 이미지로 처리되지만, 실제로 micro-Doppler 는 시간적 연속성이 중요한 신호이다. 따라서 CNN 뒤에 temporal pooling 이나 recurrent layer 를 결합하면 특정 시간 구간의 국소 패턴뿐 아니라 전체 동작 순서를 더 잘 반영할 수 있다.

평가 측면에서는 aspect-only, range-only, SNR-only 실험을 분리하는 것이 필요하다. 본 held-out 실험은 aspect 와 range 를 동시에 변화시켰으므로 두 요인의 독립적인 기여도를 구분하기 어렵다. 향후에는 aspect angle 만 60-80 deg 로 바꾸고 range 는 6-18 m 로 유지하는 실험, range 만 18-26 m 로 바꾸고 aspect 는 0-60 deg 로 유지하는 실험을 추가하여 ablation study 를 구성할 수 있다. 마지막으로 실제 측정 데이터에 대한 검증이 필요하다. 시뮬레이션 데이터는 통제된 조건에서 모델 성능을 분석하기에 적합하지만, 실제 레이더 데이터는 clutter, multipath, body shape variation, sensor synchronization error 등을 포함한다. 따라서 시뮬레이션 기반 baseline 모델을 실제 데이터로 fine-tuning 하거나 domain adaptation 을 적용하는 방향이 실용적 후속 연구가 될 수 있다.

2.13 평가 지표 해석

본 실험에서 가장 기본적인 성능 지표는 accuracy 이다. Accuracy 는 전체 평가 샘플 중 정답으로 분류된 샘플의 비율이며, baseline 조건에서는 3,000 개 test sample 이 모두 정답으로 분류되어 100.0%를 기록하였다. Held-out 조건에서는 600 개 중 534 개가 정답으로 분류되어 89.0% 정확도를 보였다. 이 수치는 전체적인 성능 수준을 빠르게 파악하는 데 유용하지만, 클래스별 편차를 설명하기에는 충분하지 않다. Class-wise accuracy 는 각 활동 클래스별로 별도 계산한 정확도이다. 본 실험에서는 각 클래스가 동일한 100 개 held-out sample 로 구성되었으므로 class accuracy 와 class recall 을 동일한 의미로 해석할 수 있다. Walk 클래스의 70.0% 정확도는 100 개 중 70 개만 정답으로 분류되었음을 의미하며, fall 과 idle 의 100.0%는 각 클래스의 모든 held-out sample 이 올바르게 분류되었음을 의미한다. Confusion matrix 는 어떤 클래스가 어떤 클래스로 오분류되는지를 보여주므로 결과 해석에서 가장 중요한 도구이다. 전체 정확도만 보면 held-out 조건에서도 89.0%로 비교적 높은 성능처럼

보이지만, confusion matrix 를 보면 walk 가 wave 로 21 개, sit_down 으로 9 개 분류되는 특정 오류 패턴이 존재한다.

2.16 실제 시스템 적용 시 고려사항

실제 레이더 HAR 시스템에 적용하려면 더 복잡한 환경을 고려해야 한다. 실제 실내 환경에서는 벽, 바닥, 주변 물체에 의한 multipath 가 발생하고, 사람 이외의 움직이는 물체가 clutter 로 작용할 수 있다. 또한 사람의 키, 보행 속도, 팔 흔들림 정도, 옷차림, 센서 설치 높이 등도 micro-Doppler signature 에 영향을 준다. 센서 하드웨어 측면에서는 sampling rate, chirp repetition interval, bandwidth, antenna beamwidth 가 spectrogram 품질을 결정한다. 예를 들어 PRF 가 충분하지 않으면 빠른 limb motion 이 Doppler aliasing 을 유발할 수 있고, range resolution 이 낮으면 target range bin 추출 정확도가 떨어질 수 있다. 따라서 모델 성능은 AI 구조뿐 아니라 레이더 파라미터 설계와도 밀접하게 연결된다.

운용 측면에서는 실시간 처리 가능성도 중요하다. ResNet-18 은 높은 정확도를 제공하지만 파라미터 수가 약 1,117 만 개이므로 임베디드 시스템에서는 연산량과 메모리 사용량을 고려해야 한다. 실제 탑재 환경에서는 MobileNet, ShuffleNet, 작은 CNN 구조와의 비교가 필요할 수 있다. 반면 서버 또는 GPU 환경에서는 더 깊은 모델이나 ensemble 방법을 사용할 수도 있다.

III. 결 론

본 논문에서는 target-range micro-Doppler spectrogram 기반 사람 활동 인식 문제에 ResNet-18 분류기를 적용하고, baseline 조건과 held-out aspect/range 조건에서의 성능을 비교하였다. Baseline 데이터는 aspect angle 0-60 deg, target range 6-18 m, SNR 5-25 dB 조건으로 구성하였으며, 10 epoch 학습 결과 동일 분포 test set 에서 100.0% 정확도를 달성하였다. 반면, aspect angle 60-80 deg 및 target range 18-26 m 의 held-out 조건에서는 정확도가 89.0%로 감소하였다. 이는 baseline 대비 11.0%p 의 성능 저하에 해당한다. 클래스별 분석에서는 walk 의 정확도가 70.0%로 가장 크게 낮아졌으며, wave 와 sit_down 으로의 오분류가 주요 원인으로 나타났다. Fall 과 idle 은 held-out 조건에서도 100.0% 정확도를 유지하였다.

결과적으로 본 실험은 ResNet-18 기반 micro-Doppler HAR 모델이 동일 분포에서는 매우 높은 성능을 보이지만, 관측 각도와 거리 조건이 변화하면 일부 클래스에서 일반화 성능이 저하될 수 있음을 확인하였다. 향후에는 aspect angle, range, SNR 을 독립적으로 변화시키는 ablation study 와 실제 측정 데이터 기반 검증이 필요하다. 또한 data augmentation, multi-aspect training, domain adaptation 등을 적용하면 관측 조건 변화에 대한 강건성을 향상시킬 수 있을 것으로 판단된다.

참고문헌

- 1) Chen, V. C., Li, F., Ho, S. S. and Wechsler, H., "Micro-Doppler Effect in Radar: Phenomenon, Model, and Simulation Study," IEEE Transactions on Aerospace and Electronic Systems, Vol. 42, No. 1, 2006, pp. 2~21.
- 2) Kim, Y. and Ling, H., "Human Activity Classification Based on Micro-Doppler Signatures Using a Support Vector Machine," IEEE Transactions on Geoscience and Remote Sensing, Vol. 47, No. 5, 2009, pp. 1328~1337.
- 3) He, K., Zhang, X., Ren, S. and Sun, J., "Deep Residual Learning for Image Recognition," Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, June 2016, pp. 770~778.
- 4) Simonyan, K. and Zisserman, A., "Very Deep Convolutional Networks for Large-Scale Image Recognition," International Conference on Learning Representations, 2015, pp. 1~14.
- 5) Remilab CNU, "Radar AI Projects: P02 ResNet18 HAR," GitHub Repository, 2026.
- 6) Graduate Radar AI Course, "Week 11: Target-Range Micro-Doppler HAR," Chungnam National University, 2026.
- 7) Graduate Radar AI Course, "Week 14: Final Project Guideline," Chungnam National University, 2026.

과제 파일 주소

https://github.com/11kkke/Radar_AI_project/upload/main